

**clase 22 de agosto 2023**

Susana Hernández

Invalid Date

## **Table of contents**

# Preface

This is a Quarto book.

To learn more about Quarto books visit <https://quarto.org/docs/books>.

# 1 Introduction

This is a book created from markdown and executable code.

See Knuth (1984) for additional discussion of literate programming.

## 2 Summary

In summary, this book has no content whatsoever.

## 3 Tarea 1

---

**Listing 3.1** Exploring functions to generate random variables with a Bernoulli distribution.py

---

```
import numpy as np
from scipy.stats import bernoulli
import matplotlib.pyplot as plt
fig_01, ax_01 = plt.subplots(1, 1)
fig_02, ax_02 = plt.subplots(1, 1)
p = 0.3
mean, var, skew, kurt = bernoulli.stats(p, moments='mvsk')
print(mean, var, skew, kurt)

x = np.arange(bernoulli.ppf(0.01, p),
              bernoulli.ppf(0.99, p))
ax_01.plot(x, bernoulli.pmf(x, p), 'bo', ms=8, label='bernoulli pmf')
ax_01.vlines(x, 0, bernoulli.pmf(x, p), colors='b', lw=5, alpha=0.5)
r = bernoulli.rvs(p, size=1000)
ax_02.hist(r, bins=200)
plt.show()
```

---









Figure 3.1: Figura 3









---

**Listing 3.2** Exploring functions to generate random variables with a Gaussian distribution.py

---

---

**Listing 3.3** Revising multivariate Gaussian.py

---

```
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import axes3d
from scipy.stats import multivariate_normal

x = np.linspace(0, 5, 100, endpoint=False)
y = multivariate_normal.pdf(x, mean=2.5, cov=0.5);

fig1 = plt.figure()
ax = fig1.add_subplot(111)
ax.plot(x, y)
# plt.show()

x, y = np.mgrid[-5:5:.1, -5:5:.1]
pos = np.dstack((x, y))
rv = multivariate_normal([0.5, -0.2], [[2.0, 0.3], [0.3, 0.5]])
fig2 = plt.figure()

ax2 = fig2.add_subplot(111)
ax2.contourf(x, y, rv.pdf(pos))
# plt.show()

ax = plt.figure().add_subplot(projection='3d')
ax.plot_surface(
    x,
    y,
    rv.pdf(pos),
    edgecolor='royalblue',
    lw=0.5,
    rstride=8,
    cstride=8,
    alpha=0.4
)
ax.contour(x, y, rv.pdf(pos), zdir='z', offset=-.2, cmap='coolwarm')
ax.contour(x, y, rv.pdf(pos), zdir='x', offset=-5, cmap='coolwarm')

ax.contour(x, y, rv.pdf(pos), zdir='y', offset=5, cmap='coolwarm')

ax.set(
    xlim=(-5, 5),
    ylim=(-5, 5),
    zlim=(-0.2, 0.2),
    xlabel='X',
    ylabel='Y',
    zlabel='Z'
)
plt.show()
```

## 4 Tarea 2

Sea  $Y_{\delta,h}(t)$  una caminata aleatoria. Demuestre que para  $\delta$  y  $h$  pequeño tenemos

$$E \exp[i\lambda Y_{\delta,h}(t)] \approx \exp \left[ -\frac{t\lambda^2 h^2}{2\delta} - \frac{t\lambda^4 h^4}{12\delta} \right]$$

### Demostración:

Considere una caminata aleatoria que comienza en 0 con saltos  $h$  y  $-h$  igualmente probables en los momentos  $\delta, 2\delta, \dots$ , donde  $h$  y  $\delta$  son números positivos. Más precisamente, sea  $\{X_n\}_{n=1}^{\infty}$  una sucesión de elementos aleatorios independientes e idénticamente distribuidos. variables con

$$P[X_i = h] = P[X_i = -h] = \frac{1}{2}, \forall i,$$

Sea  $Y_{\delta,h}(0) = 0$  y pongamos

$$Y_{\delta,h}(n\delta) = X_1 + X_2 + \dots + X_n.$$

Para  $t > 0$ , defina  $Y_{\delta,h}(t)$  mediante linealización, es decir, para  $n\delta < t < (n+1)\delta$ , defina

$$Y_{\delta,h}(t) = \frac{(n+1)\delta - t}{\delta} Y_{\delta,h}(n\delta) + \frac{t - n\delta}{\delta} Y_{\delta,h}((n+1)\delta).$$

Calculemos la función característica de  $Y_{\delta,h}(t)$ , donde  $\lambda \in \mathbb{R}$  fijo y sea  $t = n\delta$  así,  $n = t/\delta$ . Entonces se tiene que

$$\begin{aligned} E \exp [i\lambda Y_{n,\delta}(t)] &= \prod_{j=1}^n E e^{i\lambda X_j}, \text{ por ser variables independientes,} \\ &= (E e^{i\lambda X_j})^n, \text{ por ser idénticamente distribuidas,} \\ &= \frac{1}{2}(e^{i\lambda h} + e^{-i\lambda h})^n, \\ &= (\cos(\lambda h))^n, \\ &= (\cos(\lambda h))^{t/\delta}, \end{aligned} \tag{4.1}$$

(4.2)

Por otro lado, sea  $u = [\cos(\lambda h)]^{1/\delta} \Rightarrow \ln(u) = \frac{1}{\delta} \ln[\cos(\lambda h)]$ .

Usando la expansión de Taylor de  $\cos(x)$  se tiene que

$$\cos(\lambda h) \approx 1 - \frac{(\lambda h)^2}{2!} + \frac{(\lambda h)^4}{4!},$$

entonces

$$\begin{aligned} \ln(\cos(\lambda h)) &\approx \ln \left[ 1 - \frac{(\lambda h)^2}{2} + \frac{(\lambda h)^4}{4!} \right] \\ &\approx -\frac{(\lambda h)^2}{2!} + \frac{(\lambda h)^4}{4!} - \frac{1}{2} \left( -\frac{\lambda^2 h^2}{2!} + \frac{\lambda^4 h^4}{4!} \right)^2 \\ &= -\frac{\lambda^2 h^2}{2!} + \frac{\lambda^4 h^4}{4!} - \frac{1}{2} \left( \frac{\lambda^4 h^4}{4} - \frac{\lambda^6 h^6}{24^2} + \frac{\lambda^8 h^8}{24} \right) \\ &= -\frac{\lambda^2 h^2}{2} + \frac{\lambda^4 h^4}{24} - \frac{\lambda^4 h^4}{8} - \frac{\lambda^6 h^6}{(2)24^2} + \frac{\lambda^8 h^8}{48} \\ &= -\frac{\lambda^2 h^2}{2} - \frac{\lambda^4 h^4}{12} - \frac{\lambda^6 h^6}{(2)24^2} + \frac{\lambda^8 h^8}{48} \end{aligned} \quad (4.3)$$

para una  $h$  pequeña, se satisface que,

$$-\frac{\lambda^6 h^6}{(2)24^2} + \frac{\lambda^8 h^8}{48} \approx 0$$

Por lo tanto,  $\ln(\cos(\lambda h)) \approx -\frac{\lambda^2 h^2}{2} - \frac{\lambda^4 h^4}{12}$ . Así, para  $\delta$  y  $h$  pequeña, se tiene que  $\ln u \approx \frac{1}{\delta} \left( -\frac{\lambda^2 h^2}{2} - \frac{\lambda^4 h^4}{12} \right)$ . Entonces

$$u \approx \exp \left[ \frac{1}{\delta} \left( -\frac{\lambda^2 h^2}{2} - \frac{\lambda^4 h^4}{12} \right) \right] \quad (4.4)$$

Entonces por la ecuación (Equation ??)

$$E \exp [i\lambda Y_{n,\delta}(t)] \approx \exp \left[ -\frac{t\lambda^2 h^2}{2\delta} - \frac{t\lambda^4 h^4}{12\delta} \right] \quad (4.5)$$

Calculando el limite

$$\lim_{\delta \rightarrow 0} E [\exp (i\lambda Y_{n,\delta}(t))] = \lim_{\delta \rightarrow 0} \exp \left[ -t \left( \left[ \frac{h^2}{\delta} \right] \left( \frac{\lambda^2}{2} - \frac{\lambda^4 h^2}{24} \right) \right) \right],$$

Asumamos que  $\delta \rightarrow 0$ ,  $h \rightarrow 0$  pero  $h^2/\delta \rightarrow \infty$ . Entonces  $\lim_{\delta \rightarrow 0} Y_{\delta,h}(t)$  no existe. Por otro lado, consideremos la siguiente renormalización,

$$\begin{aligned}
E \exp \left[ i\lambda Y_{n,\delta}(t) + \frac{th^2\lambda^2}{2\delta} \right] &= E \left[ \exp(i\lambda Y_{n,\delta}(t)) \exp \left( \frac{th^2\lambda^2}{2\delta} \right) \right] \\
&= \exp \left( \frac{th^2\lambda^2}{2\delta} \right) E \exp [i\lambda Y_{n,\delta}(t)] \\
&\approx \exp \left( \frac{th^2\lambda^2}{2\delta} \right) \exp \left[ -\frac{t\lambda^2 h^2}{2\delta} - \frac{t\lambda^4 h^4}{12\delta} \right] \\
&= \exp \left( -\frac{t\lambda^4 h^4}{12\delta} \right)
\end{aligned} \tag{4.6}$$

Así, si  $\delta, h \rightarrow 0$  de tal manera que  $h^2/\delta \rightarrow \infty$  y  $h^4/\delta \rightarrow 0$ , entonces

$$\lim_{\delta \rightarrow 0} E \left[ \exp \left( i\lambda Y_{n,\delta}(t) + \frac{th^2\lambda^2}{2} \right) \right] = \lim_{\delta \rightarrow 0} \exp \left( \frac{(\lambda h)^4}{24\delta} \right) = 1$$



## 5 Tarea 3

**Exercise 5.1** (Ejercicio 1:). Si  $X \sim N(\mu, \sigma)$  entonces  $\left(\frac{X - \mu}{\sigma}\right) \sim N(0, 1)$ .

*Proof.* Calculemos la función característica de la variable  $\frac{X - \mu}{\sigma}$ ,

\$\$

```
\begin{aligned}
\varphi_{\frac{X-\mu}{\sigma}}(t) &= E\left[e^{it\left(\frac{X-\mu}{\sigma}\right)}\right] \\
&= E\left[e^{i\left(\frac{tX}{\sigma} - \frac{t\mu}{\sigma}\right)}\right] \\
&= e^{-\frac{it\mu}{\sigma}} E\left[e^{i\frac{tX}{\sigma}}\right] \\
&= e^{-\frac{it\mu}{\sigma}} \int_{-\infty}^{\infty} e^{i\frac{tx}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\
&= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{i\frac{tx}{\sigma}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\
&= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{i\frac{tx}{\sigma} - \frac{(x-\mu)^2}{2\sigma^2}} dx \\
&= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2} \frac{(x-\mu)^2 - 2itx\sigma}{\sigma^2}} dx
\end{aligned}
```

\$\$\{\#eq-1.1\}

$$\begin{aligned}
 \varphi_{\frac{X-\mu}{\sigma}}(t) &= E\left[e^{it\left(\frac{X-\mu}{\sigma}\right)}\right] \\
 &= E\left[e^{\left(\frac{itX}{\sigma} - \frac{it\mu}{\sigma}\right)}\right] \\
 &= e^{-\frac{it\mu}{\sigma}} E\left[e^{\left(\frac{itX}{\sigma}\right)}\right] \\
 &= e^{-\frac{it\mu}{\sigma}} \int_{-\infty}^{\infty} e^{\frac{itx}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\
 &= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{\frac{itx}{\sigma}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\
 &= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{\frac{itx}{\sigma} - \frac{(x-\mu)^2}{2\sigma^2}} dx \\
 &= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2} \frac{(x-\mu)^2 - 2itx\sigma}{\sigma^2}} dx
 \end{aligned} \tag{5.1}$$

Observemos que,

$$\begin{aligned}
\frac{(x - \mu)^2 - 2itx\sigma}{\sigma^2} &= \frac{x^2 - 2x\mu + \mu^2 - 2itx\sigma}{\sigma^2} \\
&= \frac{x^2}{\sigma^2} - \frac{2x\mu}{\sigma^2} + \frac{\mu^2}{\sigma^2} - \frac{2itx\sigma}{\sigma^2} \\
&= \frac{x^2}{\sigma^2} - \frac{2x}{\sigma} \left( \frac{\mu + it\sigma}{\sigma} \right) + \frac{\mu^2}{\sigma^2} \\
&= \left( \frac{x}{\sigma} - \left( \frac{\mu + it\sigma}{\sigma} \right) \right)^2 - \left( \frac{\mu + it\sigma}{\sigma} \right)^2 + \frac{\mu^2}{\sigma^2} \\
&= \left( \frac{x}{\sigma} - \left( \frac{\mu + it\sigma}{\sigma} \right) \right)^2 - \frac{2it\sigma\mu}{\sigma^2} - \frac{(it\sigma)^2}{\sigma^2} \\
&= \left( \frac{x}{\sigma} - \left( \frac{\mu + it\sigma}{\sigma} \right) \right)^2 - \frac{2it\mu}{\sigma} + t^2.
\end{aligned} \tag{5.2}$$

Sustituyendo (??) en ((eq?)-{1.1}), resulta

$$\begin{aligned}
\varphi_{\frac{x-\mu}{\sigma}}(t) &= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2} \left[ \left( \frac{x}{\sigma} - \left( \frac{\mu + it\sigma}{\sigma} \right) \right)^2 - \frac{2it\mu}{\sigma} + t^2 \right]} dx \\
&= e^{-\frac{it\mu}{\sigma}} e^{\frac{it\mu}{\sigma} - \frac{t^2}{2}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2} \left( \frac{x}{\sigma} - \left( \frac{\mu + it\sigma}{\sigma} \right) \right)^2} dx \\
&= e^{-\frac{t^2}{2}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2} \left( \frac{x}{\sigma} - \left( \frac{\mu + it\sigma}{\sigma} \right) \right)^2} dx
\end{aligned} \tag{5.3}$$

Sea  $u = \frac{x}{\sigma} - \left( \frac{\mu + it\sigma}{\sigma} \right) \Rightarrow du = \frac{1}{\sigma} dx$ , sustituyendo esto en (??), resulta

$$\varphi_{\frac{x-\mu}{\sigma}}(t) = e^{-\frac{t^2}{2}} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} du \tag{5.4}$$

de aquí se sigue que  $u \sim N(0, 1)$ , entonces

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} dx = 1.$$

sustituyendo esto ultimo en (??), se tiene,

$$\varphi_{\frac{x-\mu}{\sigma}}(t) = e^{-\frac{t^2}{2}}, \tag{5.5}$$

Por otro lado, consideremos  $Z \sim N(0, 1)$ , entonces

$$\varphi_Z(t) = e^{-\frac{t^2}{2}}.$$

Entonces  $\varphi_Z(t) = \varphi_{\frac{X-\mu}{\sigma}}(t)$ , como las funciones características coinciden se concluye que  $\frac{X-\mu}{\sigma} \sim N(0, 1)$ .

□

**Exercise 5.2** (Ejercicio 2:). Si  $Y \sim N(0, 1)$  entonces  $\sigma Y + \mu \sim N(\mu, \sigma)$ .

*Proof.* Calculemos la función característica de la variable  $\sigma Y + \mu$ ,

$$\begin{aligned}
 \varphi_{\sigma Y + \mu}(t) &= E[e^{it(\sigma Y + \mu)}] \\
 &= E[e^{it\sigma Y + it\mu}] \\
 &= e^{it\mu} E[e^{it\sigma Y}] \\
 &= e^{it\mu} \int_{-\infty}^{\infty} e^{it\sigma y} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy \\
 &= e^{it\mu} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(y^2 - 2yit\sigma)} dy.
 \end{aligned} \tag{5.6}$$

Observemos que,

$$\begin{aligned}
 y^2 - 2yit\sigma &= (y - it\sigma)^2 - (it\sigma)^2 \\
 &= (y - it\sigma)^2 + t^2\sigma^2.
 \end{aligned} \tag{5.7}$$

Sustituyendo, (??) en (??) resulta

$$\begin{aligned}
 \varphi_{\sigma Y + \mu}(t) &= e^{it\mu} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}((y - it\sigma)^2 + t^2\sigma^2)} dy \\
 &= e^{it\mu} e^{-\frac{1}{2}t^2\sigma^2} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(y - it\sigma)^2} dy
 \end{aligned} \tag{5.8}$$

Tomando  $u = y - it\sigma \Rightarrow du = dy$ , se tiene que

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(y - it\sigma)^2} dy = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{u^2}{2}} du,$$

entonces  $U \sim N(0, 1)$ , por lo tanto,

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(y - it\sigma)^2} dy = 1$$

sustituyendo esto ultimo en (??), resulta,

$$\varphi_{\sigma Y + \mu}(t) = e^{it\mu} e^{-\frac{1}{2}t^2\sigma^2} = e^{it\mu - \frac{t^2\sigma^2}{2}}.$$

Sea  $Z$  una variable aleatoria tal que  $Z \sim N(\mu, \sigma)$  sabemos que,

$$\varphi_Z(t) = e^{it\mu - \frac{t^2\sigma^2}{2}}.$$

De estas dos ultimas igualdades se sigue que,

$$\varphi_Z(t) = \varphi_{\sigma Y + \mu}(t).$$

Dado que tienen iguales funciones características se concluye que,

$$\sigma Y + \mu \sim N(\mu, \sigma)$$

□

**Exercise 5.3** (Ejercicio 3:). Si  $X \sim N(\mu_1, \sigma_1^2)$ ,  $Y \sim N(\mu_2, \sigma_2^2)$  además  $X$  y  $Y$  son independientes entonces  $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ .

*Proof.* Por definición, se tiene que,

$$\begin{aligned} \varphi_{X+Y}(t) &= E[e^{it(X+Y)}] \\ &= E[e^{itX}e^{itY}] \text{ por ser independientes, del ejercicio 4} \\ &= E[e^{itX}]E[e^{itY}] \\ &= \varphi_X(t)\varphi_Y(t). \end{aligned} \tag{5.9}$$

Por otro lado, sea  $Z$  una variables aleatoria tal que,  $Z \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ , sabemos que la función característica de  $Z$ , esta dada por,

$$\begin{aligned} \varphi_Z(t) &= e^{it(\mu_1+\mu_2) - \frac{t^2}{2}(\sigma_1^2+\sigma_2^2)} \\ &= e^{it\mu_1 - \frac{t^2\sigma_1^2}{2} + it\mu_2 - \frac{t^2\sigma_2^2}{2}} \\ &= e^{it\mu_1 - \frac{t^2\sigma_1^2}{2}} e^{it\mu_2 - \frac{t^2\sigma_2^2}{2}} \\ &= \varphi_X(t)\varphi_Y(t), \end{aligned}$$

entonces, de esta ultima igualdad y de (??) se sigue que,

$$\varphi_Z(t) = \varphi_{X+Y}(t).$$

Como las funciones características coinciden se sigue que,  $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ .

□

**Exercise 5.4** (Ejercicio 4:). Si  $X, Y$  son variables aleatorias normales entonces  $X, Y$  son independientes si y solo si  $E(XY) = E(X)E(Y)$ .

*Proof.* Primero recordemos que

$$E(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_{XY}(x, y) dx dy$$

Como  $X, Y$  son independientes, sabemos que

$$f_{XY}(x, y) = f_X(x) f_Y(y)$$

Entonces

$$\begin{aligned} E(XY) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_{XY}(x, y) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_X(x) f_Y(y) dx dy \\ &= \left( \int_{-\infty}^{\infty} x f_X(x) dx \right) \left( \int_{-\infty}^{\infty} y f_Y(y) dy \right) \\ &= E(X) E(Y) \end{aligned}$$

□

**Theorem 5.1** (Desigualdad de Chebyshev). Sea  $X$  una variable aleatoria con esperanza  $\mu = E(X)$  y sea  $\varepsilon > 0$ . Entonces

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}$$

*Proof.* Sea  $Y = |X - \mu|$ , observemos que  $Y$  es positiva, así por la desigualdad de Markov y dado que  $\mathcal{P}[|X - \mu| \geq \varepsilon] = \mathcal{P}[|X - \mu|^2 \geq \varepsilon^2]$ , se cumple que

$$\begin{aligned} \mathcal{P}[|X - \mu| \geq \varepsilon] &= \mathcal{P}[|X - \mu|^2 \geq \varepsilon^2] \\ &\leq \frac{E[(X - \mu)^2]}{\varepsilon^2} = \frac{\text{Var}[X]}{\varepsilon^2} \end{aligned}$$

□

**Theorem 5.2** (Ley de los grandes números). Sean  $X_1, X_2, \dots, X_n$  procesos de ensayos independientes, con esperanza finita  $\mu = E(X_j)$  y varianza finita  $\sigma^2 = \text{Var}(X_j)$ . Sean  $S_n = X_1 + X_2 + \dots + X_n$ . Entonces para cada  $\epsilon > 0$ .

$$\mathcal{P} \left[ \left| \frac{S_n}{n} - \mu \right| \geq \epsilon \right] \rightarrow 0$$

*Proof.* Observemos que

$$\begin{aligned} \text{Var} \left[ \frac{S_n}{n} - \mu \right] &= \frac{1}{n^2} \text{Var}(S_n) \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i), \text{ por ser iid} \\ &= \frac{\sigma^2}{n} \end{aligned}$$

Entonces, por el Teorema 5.1,

$$\mathcal{P} \left[ \left| \frac{S_n}{n} - \mu \right| \geq \epsilon \right] \leq \frac{\sigma^2}{n\epsilon},$$

así, tomando el limite cuando  $n \rightarrow \infty$

$$\frac{\sigma^2}{n\epsilon} \rightarrow 0.$$

Entonces

$$\mathcal{P} \left[ \left| \frac{S_n}{n} - \mu \right| \geq \epsilon \right] \rightarrow 0$$

□

**Theorem 5.3** (Teorema del Limite Central). Sea  $\{X_i\}_{i=1}^{\infty}$  una secuencia de v.a.i.id con media  $a$  y varianza  $b^2$ . Entonces para doo  $\alpha, \beta \in \mathbb{R}$ , con  $\alpha < \beta$ , entonces

$$\mathcal{P} \left( \lim_{M \rightarrow \infty} \alpha \leq \frac{\sum_{i=1}^M X_i - Ma}{\sqrt{Mb}} \leq \beta \right) = \frac{1}{\sqrt{2\pi}} \int_{\alpha}^{\beta} e^{-\frac{1}{2}x^2} dx$$

*Proof.* Definamos a

$$S_M = \sum_{i=1}^M [X_i - a],$$

y

$$Y_M = \frac{S_M}{\sqrt{Mb}}.$$

Sea  $\varphi_{Y_M}$  la función generadora de momentos de  $Y_M$  y  $\varphi$  la función generadora de momentos de la distribución normal estándar, demostraremos que  $\varphi_{Y_M} \rightarrow \varphi$ .

Por definición,

$$\begin{aligned}\varphi_{Y_M}(t) &= E \left[ \exp \left( t \frac{S_M}{\sqrt{Mb}} \right) \right] \\ &= \varphi_{S_M} \left( \frac{t}{\sqrt{Mb}} \right) \\ &= \left[ \varphi_{(X_1-a)} \left( \frac{t}{\sqrt{Mb}} \right) \right]^M \text{ ya que, las } X_i \text{ son i.i.d} \\ &= \left[ E \left[ \exp \left( \frac{t}{b\sqrt{M}} (X_1 - a) \right) \right] \right]^M\end{aligned}$$

Recordando la serie de Taylor

$$\begin{aligned}\varphi_{Y_M}(t) &= \left[ \sum_{i=0}^{\infty} \frac{E \left[ \left( \frac{t}{b\sqrt{M}} (X_1 - a) \right)^i \right]}{i!} \right]^M \\ &= \left[ 1 + \frac{1}{2} \left( \frac{t}{b\sqrt{M}} \right)^2 E[(X_1 - a)^2] + \epsilon(3) \right]^M \\ &= \left[ 1 + \frac{1}{M} \frac{t^2}{2} + \epsilon(3) \right]^M,\end{aligned}$$

donde

$$\epsilon(3) = \sum_{i=3}^{\infty} \frac{E \left[ \left( \frac{t}{b\sqrt{M}} (X_1 - a) \right)^i \right]}{i!},$$

Ahora sea  $s = \frac{t}{b\sqrt{M}}$ , así,

$$\epsilon(3) = \sum_{i=3}^{\infty} \frac{E[(X_1 - a)^i] s^i}{i!}$$

Además observemos que, cuando  $t \rightarrow 0$ ,  $s \rightarrow 0$ .

Así, de lo anterior, si  $\varphi_1$  existe, se cumple que,

$$\frac{\epsilon(3)}{s^2} = \sum_{i=3}^{\infty} \frac{E[(X_1 - a)^i] s^{i-2}}{i!} \rightarrow 0, \text{ cuando, } s \rightarrow 0.$$

Por otro lado,

$$\varphi_{Y_M}(t) = \left[ 1 + \frac{1}{M} \left[ \frac{t^2}{2} + M\epsilon(3) \right] \right]^M,$$

y  $s \rightarrow 0$  cuando  $M \rightarrow \infty$ .

Entonces  $\epsilon(3) s^{-2} = M\epsilon(3) b^2 t^{-2} \rightarrow 0$ . Dado que  $b, t$  estan fijas, se cumple que

$$M\epsilon(3) \rightarrow 0, \text{ cuando, } M \rightarrow \infty,$$

por lo tanto

$$\frac{t^2}{2} + M\epsilon(3) \rightarrow \frac{t^2}{2}, \text{ cuando, } M \rightarrow \infty$$

esto implica que,

$$\left[ 1 + \frac{1}{M} \left[ \frac{t^2}{2} + M\epsilon(3) \right] \right]^M \rightarrow \exp(t^2/2), M \rightarrow \infty$$

De aqui se concluye que,

$$\lim_{M \rightarrow \infty} \varphi_M(t) = \exp(t^2/2) = \varphi(t)$$

la cual es la función generadora de momentos de la distribución normal estándar. Por lo tanto

$$F_M(x) \rightarrow F_{N(0,1)}(x)$$

que es equivalente a,

$$F_M(b) - F_M(a) \rightarrow F_N(b) - F_N(a)$$

$$\mathcal{P} \left( \lim_{M \rightarrow \infty} \alpha \leq \frac{\sum_{i=1}^M X_i - Ma}{\sqrt{Mb}} \leq \beta \right) = \frac{1}{\sqrt{2\pi}} \int_{\alpha}^{\beta} \exp\left(-\frac{1}{2}x^2\right) dx$$

□



**Theorem 5.4.** Sea  $\{X_i\}_{i=1}^{\infty}$  una sucesión de v.a.i.i.d con media  $a$ . Entonces

$$\mathcal{P} \left[ \lim_{M \rightarrow \infty} \frac{1}{M} \sum_{i=1}^M X_i = a \right] = 1.$$

*Proof.* Esto es similar a decir que

$$\lim_{M \rightarrow \infty} \frac{1}{M} \sum_{i=1}^M X_i \stackrel{\text{c.s.}}{=} a$$

Sin pérdida de generalidad, diremos que  $X_i \geq 0, \forall i$ . Definamos

$$Y_n = X_n I_{[|X_n| \leq n]}, Q_n = \sum_{i=1}^n Y_i$$

Por la desigualdad de

$$\begin{aligned} \sum_{n=1}^{\infty} \mathcal{P} \left[ \left| \frac{Q_n - E[Q_n]}{n} \right| \geq \epsilon \right] &\leq \sum_{n=1}^{\infty} \frac{\text{Var}(Q_n)}{\epsilon^2 n^2} = \sum_{n=1}^{\infty} \frac{1}{\epsilon^2 n^2} \sum_{i=1}^n \text{Var}(Y_i) \\ &\leq \sum_{n=1}^{\infty} \frac{E(Y_n^2)}{\epsilon^2 n^2} = \sum_{n=1}^{\infty} \frac{1}{\epsilon^2 n^2} \int_0^n x^2 dF \\ &\leq \sum_{n=1}^{\infty} \frac{1}{\epsilon^2} \int_0^n x dF < \infty, \end{aligned}$$

donde  $F$  es la función de distribución de  $X_i$ . Luego

$$E[X_1] = \lim_{n \rightarrow \infty} \int_0^n x dF = \lim_{n \rightarrow \infty} E[Y_n] = \lim_{n \rightarrow \infty} \frac{E[Q_n]}{n}.$$

Entonces, por el Lema de Borel Canteli.  $\mathcal{P} \left[ \limsup \left( \left| \frac{Q_n - E[Q_n]}{n} \right| \geq \epsilon \right) \right] = 0$

$$\lim_{n \rightarrow \infty} \frac{Q_n}{n} = E[X_1], \text{ c.s.}$$

Ahora, calcularemos la siguiente probabilidad

$$\sum_{i=1}^{\infty} \mathcal{P}[X_i \neq Y_i] = \sum_{i=1}^{\infty} \mathcal{P}[X_i > n]$$

como  $E[X_i] < \infty$  y  $X_i$  son v.a.i.i.d.

$$\sum_{i=1}^{\infty} \mathcal{P} [X_i > n] \leq E [X_1] < \infty$$

De nuevo, por el Lema de Borel Cantelli.

$$\mathcal{P} [\limsup [X_i \neq Y_i]] = 0, \forall i$$

Entonces

$$\begin{aligned} X_i &= Y_i, \text{ c.s} \\ \Rightarrow \frac{1}{M} \sum_{i=1}^M X_i &\rightarrow E [X_1] = \mu. \text{ c.s} \end{aligned}$$

□

## 6 Tarea 4

### 6.1 Ejercicio 1

Sea  $W(t)$  un movimiento Browniano estándar en  $[0, T]$ . Pruebe que para cualquier  $c > 0$  fijo,

$$V(t) = \frac{1}{c} W(c^2 t)$$

es un movimiento Browniano sobre  $[0, T]$ .

#### 6.1.1 Demostración

Veamos que  $V$  cumple las propiedades del movimiento Browniano.

##### 6.1.1.1 Propiedad 1 (Que comience en 0)

Se tiene que,  $V(0) = \frac{1}{c} W(c^2 \cdot 0) = 0$ .

##### 6.1.1.2 Propiedad 2 (Incrementos Independientes)

Sean  $s < t < u < v$ , por definición de  $V$ , se tiene que,

$$E[(V(t) - V(s))(V(v) - V(u))] = \frac{1}{c^2} E[(W(c^2 t) - W(c^2 s))(W(c^2 v) - W(c^2 u))]$$

Dado que  $W$  tiene incrementos independientes, se cumple que.

$$\frac{1}{c^2} E[(W(c^2 t) - W(c^2 s))(W(c^2 v) - W(c^2 u))] = \frac{1}{c^2} E[(W(c^2 t) - W(c^2 s))] E[(W(c^2 v) - W(c^2 u))]$$

Entonces  $V$  tiene incrementos independientes.

### 6.1.1.3 Propiedad 3 (Incrementos estacionarios)

Sea  $s < t$ .

$$V(t) - V(s) = \frac{1}{c} [W(c^2 t) - W(c^2 s)]$$

Por las propiedades de la definicion del movimiento Browniano.

$$\begin{aligned} E[V(t) - V(s)] &= \frac{1}{c} E[W(c^2 t) - W(c^2 s)] = 0 \\ \text{Var}[V(t) - V(s)] &= \frac{1}{c^2} \text{Var}[W(c^2 t) - W(c^2 s)] = \frac{1}{c^2} (c^2 (t - s)) = t - s \end{aligned}$$

Entonces  $V$  tiene incrementos estacionarios.

Con todo lo anterior se concluye que,  $V$  es un movimiento browniano.

## 6.2 Ejercicio 2

Hacer un script para ilustrar la propiedad de escalado del movimiento Browniano para el caso de  $c = \frac{1}{5}$ . Estar seguro que usa el mismo camino browniano discretizado en cada subplot.

## 6.3 Ejercicio 3

Modifique el script `half_brownian_refinement.py` encapsulando el código en una función. Esta función deberá recibir el extremo derecho del intervalo  $[0, T]$  y el número de incrementos  $N$  de un camino browniano base. El propósito es calcular los incrementos de relleno de una refinamiento con  $2N$  incrementos.

## 6.4 Ejercicio 4

En un script separado, incluya la función de arriba y grafique una figura con la trayectoria del browniano con 100 incrementos y muestre su refinamiento correspondiente.




Figure 6.1: Figura 1




Figure 6.2: Figura 2

---

**Listing 6.1** Browniano escalado, con  $c=1/5$ .py

---

```
import numpy as np
import matplotlib.pyplot as plt
prng = np.random.RandomState(123456789)
T = 1
n = 100
dt = 1 / (n - 1)
dw = np.sqrt(dt) * prng.standard_normal(n - 1)
w = np.concatenate(([0], dw.cumsum()))

time = np.linspace(0, T, n)
c = 0.2 # 1/5
c_time = c**2 * time
c_w = c**(-1) * w

fig, browniano_escalado = plt.subplots(2)
browniano_escalado[0].plot(time, w)
browniano_escalado[1].plot(c_time, c_w)
browniano_escalado[0].set_title('Movimiento browniano')
browniano_escalado[1].set_title('Movimiento browniano escalado')
plt.show()
```

---

---

**Listing 6.2** Browniano refinado, con refinamiento 2N.py

---

```
import numpy as np
import matplotlib.pyplot as plt
prng = np.random.RandomState(123456789)

def refined_brownian_2n(T,L):
    dt = T / L
    W = np.zeros(L + 1)
    W_refined = np.zeros(2 * L + 1)
    xi = np.sqrt(dt) * prng.normal(size=L)
    xi_half = np.sqrt(0.5 * dt) * prng.normal(size=L)
    W[1:] = xi.cumsum()
    W_ = np.roll(W, -1)

    W_half = 0.5 * (W + W_)
    W_half = np.delete(W_half, -1) + xi_half
    W_refined[1::2] = W_half
    W_refined[2::2] = W[1:]
    t = np.arange(0, T + dt, dt)
    t_half = np.arange(0, T + 0.5 * dt, 0.5 * dt)
    return t,t_half,W, W_refined
```

---



---

**Listing 6.3** Browniano refinado, con refinamiento 2N y 100 incrementos.py

---

```
import numpy as np
import matplotlib.pyplot as plt
import h_b_r as hbr

a, b, c, d = hbr.refined_brownian_2n(1, 100)

plt.plot(a, c, 'r-+')
plt.plot(
    b,
    d,
    'g*--',

    # alpha = transparencia
)
plt.show()
```

---